

TEKNOFEST 2026

5G ve Yapay Zekâ ile Akıllı Yol Güvenliđi Yarışması

RoadGuard

5G ve Yapay Zekâ ile Akıllı Yol Güvenliđi Sistemi

FİNAL TASARIM RAPORU

Takım Adı: **Nankatsu**

Takım ID: **#985007**

Başvuru ID: **#5181367**

Tarih: 28.06.2026

Bu rapordaki tüm başarımlar sayıları, gerçek test videoları ve ayrılmış (held-out) doğrulama setleri üzerinde otomatik ölçüm hattıyla elde edilmiştir; yöntem ve sonuçlar Bölüm 4'te belgelenmiştir.

İçindekiler

1	Proje Özeti	3
2	Veri Seti Oluşturulması	3
2.1	Veri Toplama Stratejisi	3
2.2	Etiketleme ve Sınıf Şeması	4
2.3	Veri Dengeleme (Data Balancing)	4
2.4	Veri Artırma (Augmentation)	4
2.5	Train / Val / Test Dağılımı	4
3	Yapay Zekâ Çözümü	5
3.1	Problemin Analizi	5
3.2	Çözüm Mimarisi	5
3.3	Çözüm Detayları	6
4	Çözümün Sınanması	7
4.1	Sinama Protokolü	7
4.2	Tespit Doğruluğu (held-out mAP / P / R / F1)	7
4.3	Davranış Tespiti (P / R / F1)	7
4.4	Plaka Okuma — A/B	8
4.5	QoD Entegrasyonu ve Talep-Yönlü Kaynak Verimliliği	9
4.6	İşleme Hızı (FPS)	9
4.7	Hız, Kanıt İzi ve Güven Dayanakları	10
5	Kaynakça	10

1. Proje Özeti

RoadGuard, yol kenarı trafik kamerası akışından **araç, plaka, hız ve riskli sürücü davranışı** tespiti yapan gerçek bir yapay zekâ çekirdeğini; bu çekirdeği **5G CAMARA Quality-on-Demand (QoD)** ve **Number Verification (NV; sürücü telefon numarasının operatör nezdinde sessiz doğrulanması)** telekom yetenekleriyle birleştiren uçtan uca bir sistemdir. Amaç, yol güvenliğini tehdit eden olayları (dikkatsiz sürüş, araç-içi telefon/sigara kullanımı, hız ihlali) gerçek zamanlı tespit etmek ve **yalnızca kritik anlarda** 5G şebeke kalitesini talep ederek bant genişliğini verimli kullanmaktır.

Proje kapsamında yürütülen başlıca faaliyetler: (i) YOLO26 tabanlı çok-aşamalı bir tespit/takip hattının tasarımı; (ii) sürücü davranışı için landmark kütüphanesi gerektirmeyen, poz-geometrisi ve nesne kanıtını birleştiren hibrit bir motor; (iii) Türk plaka formatına özgü, koruyucu karar kurallarıyla donatılmış bir plaka okuma konsensüs döngüsü; (iv) CAMARA QoD ve NV sözleşmelerini birebir taklit eden mock servisler; (v) çözümün üç gerçek test videosu ve held-out doğrulama setleri üzerinde nicel sınanması. Yapay zekâ çekirdeği (tespit, takip, kararlılık, OCR, hız, risk) **gerçektir**; telekom katmanları gerçek API sözleşmesini taklit eden **mock**'lardır — gerçek operatöre geçişte uç nokta/kimlik değişir, ayrıca saha doğrulaması gerekir. Kalite güvencesi olarak ~780 birim/perf testi, statik denetim (ruff+black) ve otomatik sürekli-entegrasyon hattı mevcuttur. İstatistiksel kanıt ayrılmış (held-out) settedir: plaka tespiti mAP50 **0,983** (P 0,982 / R 0,963). Üç gerçek test videosu ise uçtan-uca entegrasyon doğrulamasıdır (istatistiksel genelleme değil; sınıf başına N=1): davranışta sıfır çapraz yanlış-pozitif (makro-F1 1,0), plaka okumada 3/3 tam-eşleşme (CER, karakter hata oranı 0,0; sıfır yanlış-onay). Hedef GPU'da ölçülen **26–33 FPS** iş-hacmiyle kamera akışı gerçek zamanlı işlenmiştir.

2. Veri Seti Oluşturulması

2.1 Veri Toplama Stratejisi


Veri seti, açık-kaynak veri kullanımının serbest olduğu kural çerçevesinde katmanlı bir köprü stratejisiyle oluşturulmuştur. Genel araç/kişi sınıfları (car, bus, truck, motorcycle, person) COCO veri setinden temin edilir. Araç-içi davranış ve plaka sınıfları için kimlik-doğrulaması gerektirmeyen **dört açık-kaynak bbox seti** (üçü gerçek, biri sentetik) indirilip toplanmış ve PIL ile doğrulanmıştır (hepsi CC BY 4.0): license_plate (8.823 görsel), seatbelt (3.104), smoking (557) ve phone (659, sentetik render). Her setin kaynağı, lisansı ve görüntü sayısı Bölüm 5 kaynakçasında listelenmiştir; tümü izin gerektirmeyen açık-erişim verilerdir. **Veri sınırı ve telafi:** phone (sentetik, 659) ve smoking (557) görece küçüktür; telefon üretimde stok COCO cell phone nesne-kanıtı ile hand-to-ear poz-geometrisinin birleşiminden çıkarıldığından tek bir sete bağlı değildir, sigaranın yeteneği held-out mAP (0,856) ile ölçülmüştür. Veri ölçeğinin büyütülmesi, saha verisiyle kapatılacak başlıca genişleme noktasıdır.

2.2 Etiketleme ve Sınıf Şeması

Etiketler YOLO formatındadır (<class> <cx> <cy> <w> <h>, normalize). Model-uzayı sınıf adları RoadGuard kanonik taksonomisine eşlenir (ör. cell phone → phone, cigarette → smoking) — böylece model değişse de iç sözleşme sabit kalır.

2.3 Veri Dengeleme (Data Balancing)

Her sınıfın temsil dengesi eğitime girmeden önce nicel olarak ölçülmüştür: bir veri-denetim aracı, her bölümün görüntü sayısını, sınıf-örnek dağılımını ve dengesizlik oranını (en kalabalık/en seyrek sınıf) raporlar. Ölçülen oran *seatbelt* setinde **1,27**'dir (dengeli) ve setlerin görüntü dağılımı Şekil 1'de gösterilmiştir. Dengeleme iki koldan uygulanmıştır: (i) dengesizlik oranı 3'ü aşan seyrek sınıflar saptanıp bu sınıflar lehine Ultralytics augmentasyonu (mozaik, HSV-jitter, gece-gamma) güçlendirilmiş; (ii) az-temsili davranış sınıflarının (kemer, sigara) eğitimde daha sık görülmesi sağlanarak etkin örnek çeşitliliği artırılmıştır. Böylece nadir ihlal örüntüleri, baskın sınıflar tarafından bastırılmadan öğrenilmiştir.



Şekil 1: Sol: toplanan açık-kaynak setlerin görüntü dağılımı (tümü CC BY 4.0). Sağ: *license_plate* setinin %80/%10/%10 train/val/test bölünmesi (8.823 görsel).

2.4 Veri Artırma (Augmentation)

Augmentasyon, Ultralytics eğitim hattının yerleşik teknikleriyle uygulanır: **mozaik** (bağlam çeşitliliği ve küçük nesne öğrenimi), **yatay flip** (yön bağımsızlığı), **HSV jitter** (ışık/rek renk sıcaklığı), **karartma/gamma** (gece ve far-patlaması senaryoları) ve **motion blur** (yüksek hızlı araç bulanıklığı). Ablasyon için `--no-augment` ile kapatılabilir. Ek olarak, karanlık kabin görüntülerinde sürücü ROI'sine çalışma anında CLAHE+gamma parlatma uygulanır. **Overfitting kontrolü:** küçük özel setlerde aşırı-uyumu sınırlamak için patience-tabanlı erken-durdurma, ağırlık-çürümesi ve **en-iyi-val checkpoint** dağıtımı (overfit kuyruğu kullanılmaz) uygulanır; *license_plate* eğitim/val mAP'i 0,989'da stabildir (aşırı-uyum işareti yok), held-out test bölmesi ise bağımsızdır.

2.5 Train / Val / Test Dağılımı

Veri **%80 train / %10 val / %10 test** oranında (seed 42) bölünmüştür (Şekil 1); görece küçük özel setlerde doğrulama ve test bölümlerinin istatistiksel anlam taşıması için her birine %10 pay ayrılmış, sınıf-dengesiz setlerde bölme tabakalı (stratified) yapılmıştır. Komite TOGG verisi geldiğinde aynı boru hattı domain modelini tek komutla yeniden

Üretir.

3. Yapay Zekâ Çözümü

3.1 Problemin Analizi


Trafik kamerası görüntüsünden tespit, kontrollü laboratuvar koşullarından farklı yapısal zorluklar içerir. RoadGuard, bu zorlukları gerçek footage üzerinde ölçerek tanımlamış ve her birine hedefli bir tasarım kararıyla yanıt vermiştir (Tablo 1). Bu problemlerin ortak noktası, kamera gürültüsünün ve değişken görüş koşullarının kare-bazlı kararları kararsız kılmasıdır; bu nedenle RoadGuard'nın temel tercihi **kare-merkezli değil ID-merkezli** karar üretmektir — her araç bir takip kimliği (`track_id`) altında izlenir ve tüm kararlar bu kimlik üzerinde zaman içinde biriktirilerek istikrara kavuşturulur.

Tablo 1: Temel problemler ve izlenen çözüm yolları.

Problem	İzlenen çözüm
Karanlık kabin (cam-ardı sürücü)	ROI'de CLAHE + gamma parlatma
Araç tipi titremesi (car↔truck)	Alan-ağırlıklı, track-bazlı sınıf oylaması
Hayalet (phantom) track'ler	<code>min_track_frames</code> çıktı kapısı + IoU dedup
Işık değişimi / hareket bulanıklığı	Augmentasyon (gece/gamma, motion-blur) + sürücü-ROI CLAHE/gamma parlatma
Oklüzyon	ID-merkezli birikim (kısa kayıpta kimlik korunur)
Karanlık plaka il-kodu hatası (3→0/2)	Pozisyon-veto + zemin koşulu → yanlış onay yerine pending
Tek-kare yanlış-pozitif (flicker)	ID-merkezli 16/8 zaman-oylaması

3.2 Çözüm Mimarisi

Sistem, ham video akışını etiketli olay/annotation çıktısına dönüştüren bir **kaskad boru hattıdır** (Şekil 2). Ham kare önce ön-işlemeden geçer; Aşama 1 dedektörü (YOLO26 + ByteTrack + alan-ağırlıklı sınıf oyu) araçları tespit/takip eder ve yalnızca **iki ROI** üretir: sürücü kabini ve plaka bölgesi. Bu ROI'ler paralel iki Aşama 2 motoruna gider — sürücü davranışı motoru (Katman A model + Katman B per-ID zaman-oylaması) ve plaka okuma konsensüs döngüsü. Hız/swerving kestirimi ID-merkezli birikim katmanını besler; nihai çıktı olay/annotation akışı olarak dashboard, mobil ve JSONL kanıt izine yayılır. QoD tetikleri (yaklaşma, kalite, anomali) bu akıştan türetilir. (Gerçek↔mock sınırı Bölüm 1'de tanımlanmıştır.)



Şekil 2: RoadGuard kuşbakışı kaskad boru hattı (soldan sağa akış): Aşama-1 tespit/takipten iki ROI ile üç paralel Aşama-2 motoruna (sürücü davranışı || plaka okuma || hız) ve ID-merkezli birikime; QoD tetikleyici (kesikli) kritik anda 5G kalitesini talep eder.

3.3 Çözüm Detayları

Ön-İşleme. Ön-İşleme katmanı far-patlama, motion-blur, yansıma ve occlusion için config'ten aç/kapanabilen filtre kancaları sunar; mevcut sürümde fiilen uygulanan iyileştirme, OCR ve sürücü-durumu doğruluğunu artıran **ROI-düzeyi** işlemedir: plaka/sürücü kırığına CLAHE + gamma parlatma ve küçük kırık için süper-çözünürlük (gece/loş koşul telafisi).

Aşama 1 — Tespit ve Takip. Ana dedektör varsayılan olarak doğruluk-önce stok yolov26l (Ultralytics 8.4, en güncel YOLO ailesi); ByteTrack her araca benzersiz kimlik atar. Aynı aracın kareler arası sınıf salınımı (uzaktan truck, yakından car), track başına **alan-ağırlıklı sınıf oylaması** ($\text{güven} \times \text{bbox_alan/kare_alan}$) ile çözülür.

Aşama 2a — Sürücü Davranışı (iki katman). Sürücü ROI'si önce kişi kutusuna daraltılır. Katman A iki backend'den birini kullanır: fine-tune YOLO26 detection veya — fine-tune gerektirmeyen — **YOLO26-pose** keypoint geometrisi (bilek↔ağız/kulak görelî yakınlığı, yüz-genişliği biriminde, ölçek-bağımsız), nesne kanıtıyla hibrit güçlendirilir; landmark/MediaPipe kütüphanesi **kullanılmaz**. Katman B (DriverStateEngine) her track için zaman-oylaması yürütür: bir bayrak son 16 karenin en az 8'inde doğruysa aktif sayılır (tek-kare yanlış-pozitif elenir).

Aşama 2b — Plaka Okuma ve Konsensüs. Araç sweet-spot'a girince OCR etkinleşir; **özel eğitilmiş YOLO26s LP dedektörü** (custom_license_plate, held-out mAP50 0,983) plakayı sıkı kırpar. Plakaya-özel hafif ONNX motoru **fast-plate-ocr** (varsayılan; kurulu değilse EasyOCR fallback) okur. Her okuma, OCR güveni $\times$ kaynak kalitesi (LP kırık yüksekliği) ile ağırlıklanıp track ömrü boyunca **kalıcı oy havuzunda** biriktirilir. Türk plaka formatına ($\sim \backslash d\{2\} [A-Z] \{1,3\} \backslash d\{2,4\} \$$) normalize edilen okumalar pozisyon-hızlı karakter füzyonuyla birleştirilir; onay için her pozisyonda kazanan karakter ikinciye mutlak bir marjla geçmek zorundadır, aksi halde karar pending'e çevrilir — sistem **belirsiz okumayı tasarım gereği onaylamaz**.

Stabilite/Dogruluk Zırları (K-004, config-driven). (i) Kayan-karakter onay marjı (confirm_min_char_margin=2.0): pozisyon belirsizse plaka onaylanmaz, pending denir. (ii) Takip/phantom çıktı kapısı (track_id=-1, min_output_frames): kimliğe bağlanmamış hayalet tespitler olay üretmez. (iii) ROI alan tavanı (max_roi_area_ratio=0.10): anormal

büyük ROI'ler kırılır. Karar eşikleri **videoya-özel sabit içermez** ve oran-bazlıdır; kalite kapıları (asgari plaka/ROI yüksekliği) çözünürlük-ölçekli piksel minimumları kullanır.

Hız ve Swerving. Hız kalibrasyon-bağımlıdır (tripwire/ipm/metric, Kalman+EMA); kalibrasyon yoksa sistem mutlak hız iddia etmez, yalnız görelî-hız bayrağı üretir. Swerving, aracın merkez-x serisindeki ZigZag ekstremum sayımıyla (araç-genişliği birimi, saniye penceresi) kalibrasyonsuz tespit edilir.

Yazılım ve Donanım. Python 3.13, PyTorch (Ultralytics 8.4.66), fast-plate-ocr/EasyOCR, OpenCV, Shapely, FastAPI/Uvicorn. Cihaz otomatik seçilir (CUDA → MPS → CPU). Geliştirme Apple Silicon/MPS; hedef sunucu dağıtımı NVIDIA CUDA üzerindedir — gerçek ölçüm donanımı RTX 5070 Laptop GPU (4.608 CUDA çekirdeği, 8 GB VRAM, Compute 12.0/Blackwell, torch 2.8.0+cu128; bkz. Bölüm 4.6).

4. Çözümün Sınanması

4.1 Sinama Protokolü

Çözüm üç tamamlayıcı düzeyde sınanmıştır: (i) etiketli **held-out doğrulama setleri** üzerinde istatistiksel tespit doğruluğu (mAP/P/R; Bölüm 4.2); (ii) üç gerçek test videosu (kapalı otopark, TOGG; GT plaka 34TC8532) üzerinde davranış P/R/F1, plaka exact-match (CER ile), FPS (Bölüm 4.3–4.6); (iii) QoD'nin başarımlar katkısı (A/B), kare-düzeyi GT içeren kontrollü sentetik set üzerinde (Bölüm 4.5). Şartnamenin 4.5 maddesi gereği (“kanıtlanamayan hedef puanlanmaz”), rapordaki her sayı bir komuta ve artefakta bağlıdır (Bölüm 4.7).

4.2 Tespit Doğruluğu (held-out mAP / P / R / F1)



Özel sınıfların YOLO26s fine-tune eğitimi **tamamlanmıştır**; ayrılmış test bölmesinde ölçülen held-out doğrulukları Tablo 2 ile Şekil 3'de verilmiştir. Varsayılan stok yolo26l ayrıca COCO val2017 (5.000 görsel) held-out üzerinde değerlendirilmiştir (genel doğruluk göstergesi). Telefon (phone) tespiti stok yolo26l'in COCO “cell phone” sınıfıyla yapılır; ayrı özel held-out ölçümü yoktur (davranış doğruluğu Tablo 3'de video-düzeyinde verilmiştir).

Tablo 2: Held-out tespit doğruluğu (özel modeller ayrılmış test bölmesinde; stok yolo26l COCO val2017'de). license_plate üretimde varsayılan LP dedektörüdür. [†] seatbelt/smoking: fine-tune held-out sonuçları (üretim hattında opsiyonel/devre-dışı).

Model / set	mAP50	mAP50-95	Precision	Recall	F1
license_plate (yolo26s)	0,983	0,706	0,982	0,963	0,973
seatbelt (yolo26s) [†]	0,895	0,546	0,844	0,795	0,818
smoking (yolo26s) [†]	0,856	0,457	0,855	0,820	0,837
yolo26l — COCO val2017 (genel)	0,709	0,537	0,740	0,641	—

4.3 Davranış Tespiti (P / R / F1)

Üç gerçek video üzerinde video-düzeyi davranış tespiti iki dedektör profiliyle ölçülmüştür (Tablo 3). **Her iki dedektör de** çapraz yanlış-pozitif üretmez (makro-F1



Şekil 3: Sol: held-out mAP50 / mAP50-95. Sağ: özel modellerin held-out Precision / Recall / F1 (yolo26s). Stok yolo26l COCO genel settir.

1,0; phone/smoking/swerving için P=R=F1=1,0); araç sınıfı doğruluğu (accuracy) **%100**'dür. **Kapsam ve sınırlılık:** sınıf başına destek N=1; held-out istatistiksel güç yalnız smoking'i (mAP 0,856; Tablo 2) doğrudan destekler — phone stok-COCO "cell phone" sınıfıyla, swerving kalibrasyonsuz geometriyle tespit edilir; bu ikisi için held-out sınıf metriği yoktur, video sonucu uçtan-uca varlık-kanıtıdır. Emniyet kemeri (seatbelt) yalnızca held-out mAP (0,895) ile sınanmıştır; üç videoda kemer-GT örneği bulunmadığından video-düzeyi P/R/F1 raporlanmamıştır.

Tablo 3: Davranış tespiti — üç gerçek test videosunda video-senaryo düzeyi sonuç (her hücre P/R/F1). **Aşama-1 profili** yalnız ana dedektörü değiştirir; phone stok COCO "cell phone" nesne-kanıtıyla, smoking hand-to-mouth poz-geometrisiyle (COCO'da sigara sınıfı yoktur; v4 satırında özel model de etkin), swerving dedektörden bağımsız kinematiklerle üretilir.

Aşama-1 profili	phone	smoking	swerving	Makro F1
yolo26l (stok, varsayılan)	1,0/1,0/1,0	1,0/1,0/1,0	1,0/1,0/1,0	1,00
v4-finetune (A/B kıyas tabanı)	1,0/1,0/1,0	1,0/1,0/1,0	1,0/1,0/1,0	1,00

4.4 Plaka Okuma — A/B

Karanlık otopark koşulları, plaka okumayı en kritik doğrulama sınaması yapar. Base-line OCR (EasyOCR) ile üretim hattının (özel YOLO26s LP + fast-plate-ocr) A/B'si Tablo 4'tedir: fast-plate-ocr, baseline'ın video_3'teki sistematik il-kodu misread'ini (24IC8532) düzelterek sonucu **3/3 tam-eşleşme, CER 0,0**'a çekmiş, video_1/video_2'yi korumuştur; her iki hatta da **yanlış-onay sıfırdır**.

Tablo 4: Plaka okuma A/B — 3 gerçek test videosu, gerçek-değer (GT) plaka 34TC8532.

Hat	Exact-match	CER	Confirmed	Partial	Yanlış-onay
Baseline (EasyOCR · stok/v4)	2/3 (%66,7)	0,083	2	1	0
Production (custom_LP + fast-plate-ocr)	3/3 (%100)	0,0	3	0	0

En kritik tasarım garantisi: sistem belirsiz/uzak/bulanık bir okumayı **kesinleştirmemek üzere tasarlanmıştır** (üç videoda yanlış-onay görülmemiştir); yakın-net video doğru

plakayı CONFIRMED verirken belirsiz okuma `pending`'te kalır. Bu davranış Bölüm 3.3'teki onay marjı, pozisyon-veto ve zemin koşulu zırhlarının ölçülen sonucudur.

4.5 QoD Entegrasyonu ve Talep-Yönlü Kaynak Verimliliği

QoD'nin temel değeri her kareyi yüksek kalitede taşımak değil, sistemi düşük-bant genel izleme modunda çalıştırıp **yalnızca kritik anda** (yaklaşan araç, küçük/uzak plaka) 5G yüksek-kalite talep etmektir — yani **talep-yönlü kaynak verimliliği**. `vehicle_approach` tetiği şartnamenin “TOGG yaklaşınca QoD” senaryosunu birebir karşılar.

Katkı, A/B harness ile yeniden-üretilebilir biçimde ölçülür (aynı kaynak QoD OFF/ON ile koşulur). **Ölçüm sınırı:** mevcut kontrollü koşuda OFF baseline'ı zaten yeterli kalitede olduğundan doğruluk-deltası ≈ 0 'dır; pozitif delta yalnızca OFF bant/çözünürlük baskısı altında (küçük/uzak plaka ROI'si okunamaz piksele düştüğünde) beklenir. **Mevcut koşuda QoD bir doğruluk artışı göstermemiştir**; bu nedenle QoD katkısı bu raporda doğruluk iyileşmesi olarak değil, CAMARA sözleşmesine uyumlu **talep-yönlü tetikleme ve kaynak verimliliği** olarak sunulur. Doğruluk-deltasını ve bant tasarrufunu nicilemek için, üretim hattıyla hizalı üç-kollu A/B (Always-LOW / Always-HIGH / Adaptive-QoD) ve küçük/uzak-plaka baskılı bir sentetik set, finale dek tamamlanacak somut iş kalemidir.

4.6 İşleme Hızı (FPS)

İşleme hızı hem geliştirme ortamında (Apple Silicon/MPS, M4 Pro) hem de hedef sunucu donanımında (NVIDIA RTX 5070 Laptop GPU, **4.608 CUDA çekirdeği**) **gerçek ölçümle** değerlendirilmiştir (Tablo 5; her profilde 100+ kare ölçümü, 26.06.2026). CUDA, MPS geliştirme alt-sınırının (`yolo26l` $\sim 12,98$ FPS) $\approx 2\times$ 'i iş-hacmi sağlar.

Tablo 5: İşleme hızı — gerçek ölçüm: CUDA (RTX 5070 Laptop GPU) ve MPS (M4 Pro); 26.06.2026.

Profil · dedektör · imgsz	Ortalama FPS	p50 (ms)	p95 (ms)
server · yolo26l · 960 (CUDA)	27,08	36	42
laptop · yolo26s · 640 (CUDA)	32,38	30	40
server · yolo26l (MPS, M4 Pro)	$\sim 12,98$	—	—

Kare-başına **gecikme** (p95=42 ms) ile **iş-hacmi** (~ 27 FPS) ayrı büyüklüklerdir. Bu rakam **tüm hattın** (Aşama-1 + Aşama-2) değeridir; zaman-kritik olan **Aşama-1 tespiti/takip** her karede ve daha yüksek hızda çalışır, pahalı Aşama-2 (OCR/poz) ise yalnız ROI'lerde ve olay-tetiğiyle koşar. Dolayısıyla kare-örnekleme takip sürekliliğini değil, yalnızca Aşama-2 yoğunluğunu seyreltir; sistem ~ 27 FPS iş-hacmiyle 25–30 FPS'lik bir kamera akışını gerçek-zamanlı işler; p95 gecikme zarfı bu kullanım için fazlasıyla yeterlidir.

4.7 Hız, Kanıt İzi ve Güven Dayanakları

Hız/swerving. Metrik hız modülü (IPM/homografi + Kalman) uygulanmıştır ve sahne kalibrasyonu sağlandığında MAE/MAPE üretir; bu raporda mutlak hız MAE/MAPE **kap-sam dışıdır** (sahne kalibrasyonu gerektirir, finalde mekândan sağlanır). Kalibrasyon gerektirmeden çalışan ve bu raporda sınanan yetenek swerving'dir: üç videodan video_3'te tespit edilmiş ve davranış makro-F1'ine dahildir (Bölüm 4.3).

Kanıt izi ve izlenebilirlik (şartname 4.5). Rapordaki sayılar elle değil, otomatik bir ölçüm hattıyla üretilmiştir: sistem her işlemede (1) zaman-damgalı olay izi (JSONL), (2) annotated video ve (3) karar/oy dökümü çıkarır; bir metrik-raporlama aracı Bölüm 4 tablolarını bu çıktılardan toplar. Böylece her sayı izlenebilir bir ölçüme dayanır, rapora elle girilmemiştir. Otomatik test paketinin (~780 test) bir bölümü ayrıca CAMARA QoD/NV mock sözleşme uyumunu doğrular.

Güven dayanakları. Güven, ölçülen sayıların ötesinde **yapısal** gerekçelere dayanır: karar eşikleri oran/boyut-temellidir ve **videoya-özel sabit içermez** (K-004; kalite kapıları çözünürlük-ölçeklidir), dolayısıyla sonuçlar tek çekime aşırı-uyumlanmaz; belirsizlikte sistem yanlış üretmek yerine çekimser kalır (plakada **sıfır yanlış-onay**) ve bu güvenceler config-driven, gerçek videoda doğrulanmış zırlara (Bölüm 3.3) dayanır. Video setinin istatistiksel sınırı (N=1) Bölüm 4.3'te açıkça belirtilmiş olup komite verisiyle güçlendirilecektir.

5. Kaynakça

Aşağıda projede fiilen kullanılan başlıca yöntem, kütüphane ve açık-veri kaynakları (lisanslarıyla) listelenmiştir.

1. Ultralytics, *Ultralytics YOLO Documentation* (v8.4.66, YOLO26), 2026. <https://docs.ultralytics.com> (erişim 2026).
2. Y. Zhang vd., *ByteTrack: Multi-Object Tracking by Associating Every Detection Box*, ECCV, 2022. arXiv:2110.06864.
3. T.-Y. Lin vd., *Microsoft COCO: Common Objects in Context*, ECCV, 2014. arXiv:1405.0312. (CC BY 4.0)
4. ankandrew, *fast-plate-ocr*, 2024–2026. <https://github.com/ankandrew/fast-plate-ocr>.
5. JaidedAI, *EasyOCR*, 2020–2026. <https://github.com/JaidedAI/EasyOCR>. (Apache-2.0)
6. K. Zuiderveld, *Contrast Limited Adaptive Histogram Equalization (CLAHE)*, Graphics Gems IV, 1994 · R. E. Kalman, *A New Approach to Linear Filtering*, ASME J. Basic Eng., 1960. (ön-işleme / hız)
7. CAMARA Project (Linux Foundation), *Quality-on-Demand API & Number Verification API*, 2023–2026. <https://github.com/camaraproject>.
8. 3GPP, *System Architecture for the 5G System*, TS 23.501, Rel-18. <https://www.3gpp.org>.
9. keremberke, *License Plate Object Detection*, Hugging Face, 2023. (CC BY 4.0) — license_plate 8.823 görsel.
10. ramankamran, *Seatbelt Detection (YOLOv11)*, Hugging Face, 2024. (CC BY 4.0) — seatbelt 3.104 görsel.
11. *CigDet* — *Cigarette Detection*, Mendeley Data, 2021. DOI:10.17632/6hyrr8typ7.1. (CC BY 4.0) — smoking 557 görsel.
12. anywaylabs, *Synthetic Driver Monitoring*, Hugging Face, 2024. (CC BY 4.0) — phone 659 görsel.
13. M. Everingham vd., *The PASCAL VOC Challenge* (mAP metodolojisi), IJCV, 2010.